


Ethik in der KI

- KI soll **verantwortlich** sein - Idealerweise sollten wir wissen, wer oder was von einem KI-Modell getroffene Entscheidung verursacht hat.
 - KI soll **fair** sein - Frei von Vorurteilen.
 - KI soll **mensch-zentriert** sein - sie sollte menschliche Bedürfnisse in sozialen, politischen und emotionalen Kontexten beachten und respektieren.
- Wir können diese Anforderungen zu erfüllen, indem wir KI **erklärbar** machen.

Beispiel:



Unerklärbar!

- Eine möglicher Ansatz ist die Verwendung von Symbolische KI
- Ein Besonderer Ansatz ist die Verwendung von symbolische Vektorarchitekturen, auch bekannt als 'Hyperdimensional Computing' (HDC)

HDC Beispiel

Bindung:

$$\text{Wein} = \begin{bmatrix} 1 \\ -1 \\ -1 \\ 1 \end{bmatrix}, \quad \text{Rot} = \begin{bmatrix} 1 \\ 1 \\ 1 \\ -1 \end{bmatrix}, \quad \text{Weiß} = \begin{bmatrix} 1 \\ 1 \\ 1 \\ -1 \end{bmatrix}$$

Element-wise Multiplication

$$\text{Rotwein} = \text{Wein} \otimes \text{Rot}$$

$$= \begin{bmatrix} -1 \\ -1 \\ 1 \end{bmatrix} \oplus \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix} = \begin{bmatrix} -1 \\ -1 \\ -1 \end{bmatrix}$$

$$\text{Weißwein} = \begin{bmatrix} -1 \\ -1 \\ 1 \end{bmatrix} \oplus \begin{bmatrix} -1 \\ 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix}$$

Bundling

Gegeben ist eine Menge von HDVs $\{v_1, v_2, \dots, v_n\}$
 $\rightarrow$ Wir verwenden Majority vote Sum zum Bundling.

$$S = \sum_{k=1}^n v_k$$

$\rightarrow$ Then take the sign (Zeichen) von S :

$$\text{sign}(S) = \begin{cases} +1 & S \geq 0 \\ -1 & S < 0 \end{cases}$$

Beispiel:

$$\text{Weinkeller} = \text{Rotwein} \oplus \text{Weißwein}$$

$$\begin{bmatrix} -1 \\ -1 \\ -1 \end{bmatrix} \oplus \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix}$$

$$= \begin{bmatrix} 0 \\ -2 \\ -2 \end{bmatrix}$$

$$= \text{sign}\left(\begin{bmatrix} 0 \\ -2 \\ -2 \end{bmatrix}\right) = \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix}$$

Unbinding

Problem: Wir haben ein unbekanntes Getränk mit einer rosa Farbe - eine Mischung aus Rot und Weiß.

Lösung: Wir können den gebündelten Vektor Weinkeller abfragen ob es ein Wein ist.

$$\text{Rosa} = \text{Rot} \oplus \text{Weiß}$$

$$= \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix} \oplus \begin{bmatrix} -1 \\ 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 2 \\ -2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix}$$

Unbinding $\rightarrow$ Wir fragen den Weinkeller ab:

$$\text{Rose} \otimes \text{Weinkeller}$$


$$= \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix} \otimes \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}$$

Ergebnis $\neq$ Wein $\Rightarrow$ Eine verrauschte Version von Wein!

Frage: Wie können wir die ursprüngliche Version von Wein wiederherstellen?

Hopfield Network (HF)

Ein HF ist ein vollständig verbundenes neuronales Netz, das einen verrauschten oder unvollständigen Vektor (binär) aufnimmt, und die am besten passende gelernte Repräsentation ausgibt.



→ Gewichte $W \in \mathbb{R}^{N \times N}$

$N = 3$ (unser Bsp.)

$$W = \begin{bmatrix} 0 & w_{12} & w_{13} \\ w_{21} & 0 & w_{23} \\ w_{31} & w_{32} & 0 \end{bmatrix}$$

$$w_{ij} = \frac{1}{N} \sum_{n=1}^P x_i^n x_j^n$$

Beispiel: Wir können die Muster von Wein, Rot, und Weiß in diese HFF lernen.

$$P = 3, N = 3$$

$$P_1 = \begin{bmatrix} -1 \\ -1 \\ 1 \end{bmatrix}, \quad P_2 = \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix}, \quad P_3 = \begin{bmatrix} -1 \\ 1 \\ -1 \end{bmatrix}$$

Wein Rot Weiß

$$w_{12} = \frac{1}{3} [(-1)(-1) + (1)(1) + (-1)(1)] = \frac{1}{3}(1) = \frac{1}{3} \checkmark$$

$$w_{13} = \frac{1}{3} [(-1)(1) + (1)(-1) + (-1)(-1)] = \frac{1}{3}(-1) = -\frac{1}{3} \checkmark$$

$$w_{21} = \frac{1}{3} \checkmark$$

$$w_{23} = \frac{1}{3} [(-1)(1) + (1)(-1) + (1)(1)] = \frac{1}{3}(-3) = -1 \checkmark$$

$$w_{31} = w_{13} = -\frac{1}{3}$$

$$w_{32} = w_{23} = -1$$

⇒

$$W = \begin{bmatrix} 0 & 1/3 & -1/3 \\ 1/3 & 0 & -1 \\ -1/3 & -1 & 0 \end{bmatrix}$$

Frage: Wie können wir die ursprüngliche Repräsentation von Wein wiederherstellen?

x Ausgabe für x' Eingabe ist:

$$x_i = \text{sign} \left(\sum_j w_{ij} x'_j \right)$$

$$\text{Wein + Noise (Rauschen)} = x' = \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}$$

$$\begin{aligned} x_1 &= \text{sign} [w_{12} x'_2 + w_{13} x'_3] = \text{sign} \left[\frac{1}{3}(-1) + \left(-\frac{1}{3}\right)(1) \right] \\ &= \text{sign} \left(-\frac{2}{3} \right) = \boxed{-1} \end{aligned}$$

$$\begin{aligned} x_2 &= \text{sign} [w_{21} x'_1 + w_{23} x'_3] = \text{sign} \left[\frac{1}{3}(1) + (-1)(1) \right] \\ &= \text{sign} \left(-\frac{2}{3} \right) = \boxed{-1} \end{aligned}$$

$$\begin{aligned} x_3 &= \text{sign} [w_{31} x'_1 + w_{32} x'_2] = \text{sign} \left[-\frac{1}{3}(1) + (-1)(-1) \right] \\ &= \text{sign} \left(\frac{2}{3} \right) = \boxed{1} \end{aligned}$$

$$x = \begin{bmatrix} -1 \\ -1 \\ 1 \end{bmatrix} \Rightarrow \text{Wein (ursprünglich, sauber)}$$